


# Machine learning em saúde

Prof. Dr. Alexandre Chiavegatto Filho



- Inspiradas pelo funcionamento do cérebro.
- Neurônios conectados por axônios e dendritos.
- Região de contato: sinapses.
  - Sinais são propagados sequencialmente.
  - Força das conexões sinápticas dependem de estímulos externos.




*Algoritmos de*

## MACHINE LEARNING

## REDES NEURAIIS

Problemas de regressão:  $K=1$  com apenas um desfecho (*output*),  $Y_1$ .

Problemas de classificação: número de neurônios presentes no output são iguais ao número total de categorias a serem preditas.



- Weight decay: efeito similar ao da regressão ridge em modelos lineares.
  - Uma penalidade é adicionada à função perda.
- $\lambda \geq 0$  é um hiperparâmetro otimizado por validação cruzada *k-fold*. Em geral, os valores de  $\lambda$  variam entre 0 e 0,1.

$$R(\theta) + \lambda J(\theta)$$

*Algoritmos de*

MACHINE LEARNING

REDES NEURAIAS


- O modelo com apenas uma camada de unidades latentes representa a estrutura mais simples de uma rede neural.
- Outros modelos, em que mais camadas são utilizadas como passo intermediário entre os preditores e a resposta: deep learning.

*Algoritmos de*

MACHINE LEARNING

DEEP LEARNING

Redes neurais profundas (mais do que uma camada oculta), em que cada camada encontra novas representações para os dados.



*Algoritmos de*

MACHINE LEARNING

DEEP LEARNING

Três grandes tipos de modelos principais

**Redes neurais convolucionais:** utilizadas principalmente para problemas de classificação de imagens.

**Redes neurais recorrentes:** utilizadas principalmente para problemas de linguagem natural (humana).

**Perceptrons de Multicamada, ou camadas densas feedforward:** utilizadas principalmente para predição de dados estruturados.

*Algoritmos de*

MACHINE LEARNING

DEEP LEARNING

Os dados são transformados em cada neurônio por meio de pesos (parâmetros) e vieses (interceptos). O objetivo é encontrar os pesos e vieses que levem ao desfecho correto.



*Algoritmos de*

MACHINE LEARNING

DEEP LEARNING



Como medir o erro da predição para calibrar os pesos e vieses?

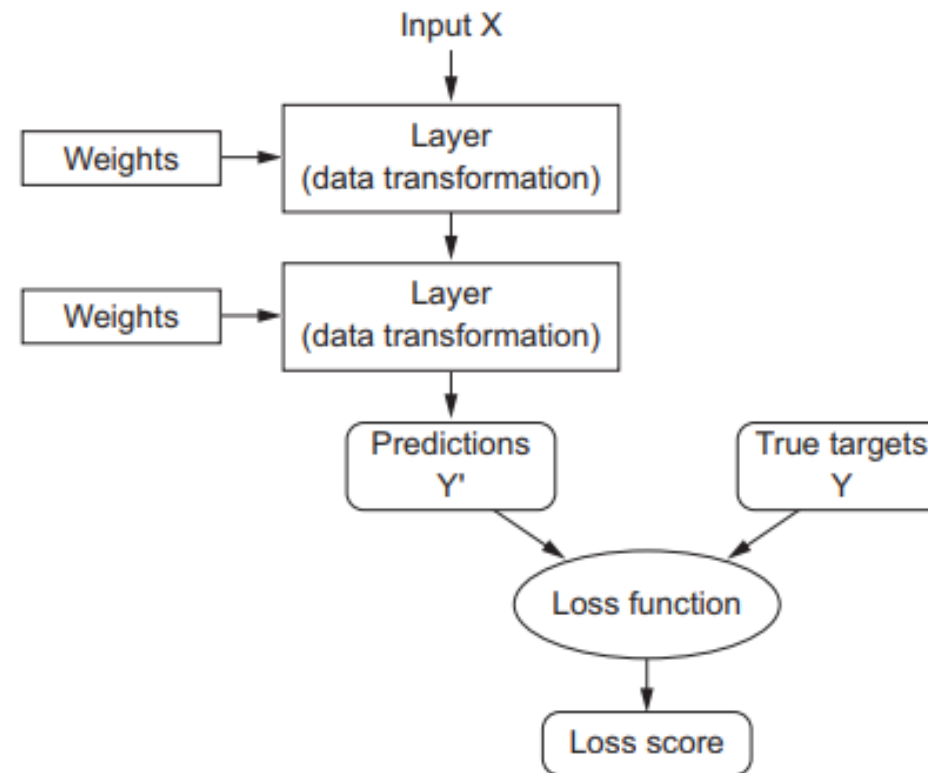
- Por meio da função de perda (ou função objetivo).
  - Regressão: erro quadrático médio.
  - Classificação: entropia cruzada.

Os pesos e vieses são ajustados de trás para frente por meio de backpropagation.

*Algoritmos de*

MACHINE LEARNING

DEEP LEARNING



*Algoritmos de*

MACHINE LEARNING

DEEP LEARNING



Os pesos e vieses são iniciados randomicamente com valores baixos.

- Nesses casos, o erro da função de perda será alto.
- Mas os erros são corrigidos pelo ajustes dos pesos de trás para frente.
- O processo é repetido diversas vezes com diferentes lotes (menos custoso computacionalmente que todos os dados) de observações sorteadas.

Como corrigir os  
erros por meio do  
ajuste dos pesos?


- Solução simples: deixar todos os pesos fixos menos um.
- Porém seria ineficiente, já que um lote de dados teria de passar pelo algoritmo para cada peso atualizado.
- Solução: usar gradient descent.
  - Calcular o gradiente da função de perda em relação aos pesos e mover o valor dos pesos na direção oposta do gradiente, diminuindo as perdas.

*Algoritmos de*

MACHINE LEARNING

Mini-batch stochastic  
gradient descent.

DEEP LEARNING



*Algoritmos de*

MACHINE LEARNING

DEEP LEARNING



- Mini-batch stochastic gradient descent.
  - Sorteio de lotes que vão sendo utilizados para calibrar os pesos.
- Figura anterior foi para um só peso.
- É possível realizar o mesmo em várias dimensões, uma para cada peso a ser estimado.

## Função de ativação

Sem uma função de ativação, os neurônios são apenas a soma dos pesos multiplicados pelos valores dos neurônios anteriores.

Isso limita a rede a aprender transformações lineares.

É preciso uma função de ativação não-linear: mais comum é relu (elimina dados negativos e permite ganhos de velocidade de computação).




Figure 3.4 The rectified linear unit function

Deep learning é composto por:

- Mais do que uma camada profunda, muitas vezes totalmente conectadas (densas).
- Função de ativação: como o sinal é modificado e passado entre neurônios.
- Função de perda, que orienta o aprendizado:
  - Entropia cruzada para desfecho binário (mede a distancia entre a realidade e a probabilidade predita).
  - Erro quadrático médio para problemas de regressão.



*Algoritmos de*

MACHINE LEARNING

DEEP LEARNING



Deep learning é composto por:

- Optimizer, que é como o gradiente da perda será usado para atualizar os pesos.  
Em geral, uma variação do stochastic gradient descent (rmsprop).
- Lotes dos dados de treino que são passados de cada vez para calibrar os pesos.

- Keras é uma biblioteca relativamente simples e com linguagem amigável para rodar modelos de deep learning.
- Bastante prática, só não é recomendada se você quiser desenvolver novos modelos ainda não existentes.
- Utiliza tensorflow.




Figure 3.2 Google web search interest for different deep-learning frameworks over time

## A BUSCA POR ALGORITMOS INTERPRETÁVEIS



Muito se fala sobre necessidade de “interpretação” dos algoritmos.

- O objetivo de uma predição **não é compreender a causalidade de um fenômeno**, é predizê-lo!
- Se o interesse for causalidade: usar métodos causais.

## A BUSCA POR ALGORITMOS INTERPRETÁVEIS



Entretanto é sim possível alguma interpretação da importância preditora das variáveis.

- Importante: não confundir com causalidade.
- Exemplo: na predição de risco de uma pessoa ir a óbito talvez seja interessante incluir o fato de ela ter sido internada em UTI recentemente.
- O fato de ela ter ido para a UTI **não é a causa** de ela ir a óbito no futuro, é apenas um preditor (ninguém cogita impedir idas à UTI para diminuir óbito).

## A BUSCA POR ALGORITMOS INTERPRETÁVEIS



Conclusão: *interpretação em machine learning não é causalidade, mas sim uma forma de entender como o algoritmo realizou a predição.*

## A BUSCA POR ALGORITMOS INTERPRETÁVEIS



Por que interpretação:

- Identificar presença de preditores indesejáveis (vazamento de dados).
- Garantir maior robustez (se o algoritmo de carro sem condutor está identificando motos pela roda, cuidado com motos com bolsas laterais).
- Identificar preconceitos (pode ser que o algoritmo esteja usando raça para rejeitar empréstimos bancários).
- Auxiliar na adesão pelos profissionais (médicos aceitarão melhor se entenderem como toma a decisão).

## A BUSCA POR ALGORITMOS INTERPRETÁVEIS

Por que **não** ter interpretação:

- Manipular o sistema:
  - Imaginem se forem divulgados como um algoritmo estabelece prioridades para receber cirurgia, e uma das variáveis for morar no Butantã (bairro menos poluído de SP). As pessoas vão começar a dizer que moram no Butantã para manipular o algoritmo.



---

**Brecha no ranking da Fifa prejudica  
seleções que jogam muitos amistosos**

# A BUSCA POR ALGORITMOS INTERPRETÁVEIS



Possibilidades para interpretação:

- Interpretação intrínseca: utilizar algoritmos interpretáveis (regressão linear/logística ou árvores simples de decisão).
- Interpretação extrínseca: utilizar técnicas que permitem retirar interpretação de algoritmos complexos após o treinamento.



## IMPORTÂNCIA DE VARIÁVEIS PREDITORAS



### Solução mais comum

- Análise da mudança do erro de predição ao **permutar valores** da variável.
  - Variável é importante para predição se erro aumenta.
  - Se o modelo não utiliza essa variável o erro não muda.
- Outras soluções envolvem o desenvolvimento de algoritmos interpretáveis que se aproximem ao mais complexo (LIME, Global Surrogate).

# Inteligência Artificial

Decisão é uma black box

Como convencer  
profissionais a adotarem  
nossos algoritmos?

- Mostrando a quantidade de acertos (performance).
- Não consigo explicar de forma simplista por que esse paciente só tem 1 mês de vida (é devido a interações muito complexas entre fatores), mas o algoritmo acerta quase sempre.
- Hora de iniciar os cuidados paliativos (caso o paciente tenha interesse), não importa o motivo.

# Inteligência Artificial

## Consequências no mercado de trabalho:

Complementação do trabalho de alguns profissionais: área da saúde.

- Impacto positivo: melhores decisões → maiores salários.
- Entretanto: necessidade de treinamento.

Alteração drásticas em outros trabalhos feitos por humanos: carros sem condutor.

- Solução: renda mínima? Incentivo a treinamentos?

# Inteligência Artificial

## Problemas sociais

Algoritmos *preconceituosos*

Exemplo recente:



- Algoritmos que ajudam juízes a estabelecer fiança nos EUA com tendência para risco maior de reincidência para negros (mais visados pela polícia → maior risco de serem presos pelo mesmo crime).

Na área da saúde: prioridades para cirurgia maior para ricos (maior tempo e dinheiro para usar na recuperação → melhores resultados da cirurgia).

# Inteligência Artificial



## Problemas sociais

Ainda estamos longe, mas consequências drásticas.

- O que essa inteligência fará com humanos?
- Pode ser que ignore, até nos ajude.

Singularidade:

- Enorme avanço tecnológico em um curto espaço de tempo.
- Inteligência de uma criança é suficiente.

# Inteligência Artificial

## Problemas sociais

Desenvolvimento de inteligência artificial forte (inteligência artificial geral).

- Capacidade de aprender novas tarefas de fato sozinha.
- Não é a realidade hoje: algoritmos que predizem órbita não conseguem jogar xadrez.

Não virá de aprendizado supervisionado.

- Impossível ensinar todas as tarefas possíveis.

# Machine learning

*“Inteligência artificial será como a eletricidade: não haverá uma única profissão que não será profundamente alterada em 10 anos.”*

Prof. Andrew Ng - Universidade de Stanford



# Machine learning *em Saúde*

<b>Objetivos:</b>	Conseguir prever a ocorrência de eventos, como óbitos ou doenças, é uma preocupação estrutural da ciência, mas que tem sido negligenciada até recentemente. O curso tem como objetivo introduzir o aluno ao uso prático dos modelos preditivos de inteligência artificial ( <i>machine learning</i> ). Programação: 1 – Perspectivas para o uso de inteligência artificial em saúde. 2 – O uso do R e do Python para limpeza, transformação e visualização de dados. 3 – Sobreajuste e divisão da amostra em treino, validação e teste. 4 – Mensuração da performance de modelos preditivos. 5 – Modelos para predição de variável contínua (regressões penalizadas com lasso e <i>ridge</i> , redes neurais, <i>support vector machines</i> , <i>random forests</i> e <i>gradient boosted trees</i> ). 6 – Modelos para predição de variável binária (regressões logísticas penalizadas, redes neurais, <i>support vector machines</i> , <i>Naïve Bayes</i> , <i>random forests</i> e <i>gradient boosted trees</i> ). 7 – <i>Deep learning</i> . 8 – Seleção, transformação e mensuração da importância das variáveis preditoras. 9 – Sobrevivência da espécie humana com a chegada da singularidade (provocações).
<b>Período de Realização:</b>	05/02/2018 a 09/02/2018 - 2.ª a 6.ª feira das 14h00 às 18h00
<b>Carga horária:</b>	20 horas
<b>Local do curso:</b>	Faculdade de Saúde Pública/USP - Av. Dr. Arnaldo, 715, Cerqueira Cesar - São Paulo/SP
<b>Vagas:</b>	25
<b>Professor:</b>	Alexandre Dias Porto Chiavegatto Filho (Coordenador)
<b>Monitora:</b>	Hellen Geremias dos Santos

Pesquisar



## Aulas USP | Inteligência Artificial em saúde: o uso de machine learning

11 vídeos • 12.382 visualizações • Última atualização em 30 de jun de 2018



Canal USPINSCRITO 68 MIL



Machine learning

*Medo de uma vida guiada por algoritmos?*

# Machine learning – medo de uma vida guiada por algoritmos?

Melhor alocação dos nossos recursos (tempo e dinheiro): menos livros e séries que não gostamos, eventos que não queremos ir, procedimentos de saúde ineficientes.

Mais tempo e dinheiro livre para o que de fato importa:

- Algoritmo não passeia meu cachorro.
- Algoritmo não abraça meus pais.
- Algoritmo não bebe um chopp com meus amigos.



Machine learning vai liberar nosso potencial humano



*Obrigado!*

Alexandre Chiavegatto Filho



<http://www.fsp.usp.br/alexandre>



@SaudenoBR



[alexdiasporto@usp.br](mailto:alexdiasporto@usp.br)